

CS 2569/

เค้าโครงโครงงานคอมพิวเตอร์

PM2.5 Air Quality Forecasting and User-Group-Based Health Advisory System

ระบบพยากรณ์ค่า PM2.5 และให้คำแนะนำด้านสุขภาพอากาศตามกลุ่มผู้ใช้

จัดทำโดย

663380391-2 นายพงศ์วิรัญจ์ จันทะฟอง

663380394-6 นายพริษฐ์ ธรรมสอน

อาจารย์ที่ปรึกษา : ผศ.บุญทรัพย์ ไวคำ

รายวิชานี้เป็นส่วนหนึ่งของการศึกษาวิชา CP354771 โครงงานทางวิทยาการคอมพิวเตอร์ 1

ภาคเรียนที่ 1 ปีการศึกษา 2569

สาขาวิชาวิทยาการคอมพิวเตอร์ วิทยาลัยการคอมพิวเตอร์

มหาวิทยาลัยขอนแก่น

การเสนอเค้าโครงโครงงานคอมพิวเตอร์

สาขาวิชาวิทยาการคอมพิวเตอร์วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

ชื่อ นาย พงศ์วิรัญจ์ จันทะฟอง รหัสประจำตัว 663380391-2

Mr.Phongwirun Juntafong

นาย พริษฐ์ ธรรมสอน รหัสประจำตัว 663380394-6

Mr.Parid Thammasorn

นักศึกษาระดับปริญญาตรี หลักสูตรวิทยาศาสตร์บัณฑิต สาขาวิทยาการคอมพิวเตอร์

อาจารย์ที่ปรึกษาโครงงาน ผศ.บุญทรัพย์ ไวคำ

Project Advisor Asst. Prof. Boonsup Waikham

1.ชื่อหัวข้อโครงงาน

ภาษาไทย ระบบพยากรณ์ค่า PM2.5 และให้คำแนะนำด้านสุขภาพอากาศตามกลุ่มผู้ใช้

ภาษาอังกฤษ PM2.5 Air Quality Forecasting and User-Group-Based Health Advisory System

2.หลักการและเหตุผล

ปัญหามลพิษทางอากาศ โดยเฉพาะค่าฝุ่นละอองขนาดเล็ก PM2.5 เป็นปัญหาที่ส่งผลกระทบโดยตรงต่อสุขภาพของประชาชน โดยเฉพาะระบบทางเดินหายใจ และส่งผลต่อการดำเนินชีวิตประจำวัน โดยจังหวัดขอนแก่นเป็นหนึ่งในพื้นที่ที่ประสบปัญหาคุณภาพอากาศในบางช่วงของปี

ในปัจจุบันประชาชนสามารถตรวจสอบค่าฝุ่น PM2.5 ณ ช่วงเวลาปัจจุบันได้จากแหล่งข้อมูลต่าง ๆ แต่ยังขาดระบบที่สามารถคาดการณ์แนวโน้มล่วงหน้า และช่วยสนับสนุนการตัดสินใจว่าช่วงเวลาใดเหมาะสมหรือไม่เหมาะสมสำหรับการทำกิจกรรมกลางแจ้ง

ดังนั้น โครงงานนี้จึงมีแนวคิดในการพัฒนาระบบที่ใช้เทคนิคการเรียนรู้ของเครื่อง (Machine Learning) เพื่อวิเคราะห์ข้อมูลคุณภาพอากาศและข้อมูลสภาพอากาศย้อนหลัง และคาดการณ์ค่า PM2.5 ล่วงหน้า พร้อมทั้งแจ้งเตือนระดับความเสี่ยงและให้คำแนะนำแก่ประชาชน

นอกจากนี้ ระดับความเสี่ยงจากฝุ่น PM2.5 ที่แต่ละกลุ่มบุคคลได้รับยังแตกต่างกันตามสภาวะร่างกายและประเภทกิจกรรมที่ทำ เช่น เด็ก ผู้สูงอายุ หรือผู้มีโรคประจำตัวทางระบบหายใจมีความเสี่ยงสูงกว่าคนทั่วไป และกิจกรรมที่ใช้แรงมาก เช่น การวิ่งหรือออกกำลังกาย ทำให้ร่างกายสูดอากาศเข้ามากกว่าการเดินเล่นทั่วไป โครงงานนี้จึงมุ่งพัฒนาระบบที่ไม่เพียงพยากรณ์ค่าฝุ่นในภาพรวม แต่ปรับคำแนะนำให้เหมาะสมกับกลุ่มผู้ใช้งานและประเภทกิจกรรมที่ต้องการทำ เพื่อให้คำแนะนำมีความหมายและนำไปใช้ได้จริงมากยิ่งขึ้น

3.วัตถุประสงค์ของโครงงาน

1. เพื่อพัฒนาโมเดล Machine Learning สำหรับพยากรณ์ค่า PM2.5 ล่วงหน้า 24 ชั่วโมงในจังหวัดขอนแก่น โดยใช้ข้อมูลคุณภาพอากาศและข้อมูลสภาพอากาศย้อนหลัง

2. เพื่อพัฒนาระบบจัดเส้นทางโมเดลแบบมีเงื่อนไข (Dynamic Routing Layer) ที่คัดเลือกโมเดลพยากรณ์ที่เหมาะสมที่สุดโดยอัตโนมัติในแต่ละรอบเวลา

3. เพื่อพัฒนาระบบ Dashboard แสดงผลค่าฝุ่นและแนวโน้มในอนาคตในรูปแบบ Progressive Web App (PWA) ที่ติดตั้งบนหน้าจอหลักของโทรศัพท์มือถือได้เหมือนแอปพลิเคชันทั่วไป

4. เพื่อพัฒนาระบบประเมินความเสี่ยงและให้คำแนะนำเฉพาะบุคคล โดยผสานผลพยากรณ์เข้ากับกลุ่มความเสี่ยงของผู้ใช้งานและความหนักของกิจกรรมกลางแจ้ง พร้อมทั้งค้นหาช่วงเวลาที่มีค่าฝุ่นต่ำที่สุดในแต่ละวันโดยอัตโนมัติ

5. เพื่อพัฒนาระบบแจ้งเตือนล่วงหน้าเชิงรุก (Proactive Alert) เมื่อคาดการณ์ว่าคุณภาพอากาศจะเปลี่ยนแปลงในทางที่แย่ลง

6. เพื่อพัฒนาส่วนอธิบายเหตุผลของการพยากรณ์ด้วยภาษาธรรมชาติ (Explainable Forecast) ที่ผ่านการตรวจสอบความปลอดภัยของเนื้อหาก่อนแจ้งเตือนผู้ใช้งาน เพื่อให้ผู้ใช้งานทั่วไปเข้าใจง่ายและเชื่อถือได้

4.ทฤษฎีและผลงานวิจัยที่เกี่ยวข้อง

4.1 กลุ่มทฤษฎีหลักและเทคนิค

4.1.1 ทฤษฎีอัลกอริทึมการเรียนรู้ของเครื่อง

- Prophet เป็นโมเดลถดถอยแบบบวก (Additive Regression) ที่ทนทานต่อข้อมูลสูญหายและ Outlier มีโครงสร้างดังสมการ

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

โดย g(t) คือแนวโน้ม (รองรับทั้งแบบเชิงเส้นและลอจิสติกส์), s(t) คือฤดูกาลที่ประมาณด้วยอนุกรมฟูเรียร์ (Fourier Series), h(t) คือผลกระทบวันหยุด และ ϵt คือความคลาดเคลื่อนแบบ White Noise การประมาณค่าพารามิเตอร์ใช้ Hierarchical Bayesian Model ทำให้ได้ทั้งค่าพยากรณ์และช่วงความเชื่อมั่น

- XGBoost เป็น Gradient Boosting Decision Tree ที่เติบโตแบบ Level-wise ใช้ฟังก์ชันวัตถุประสงค์แบบมี Regularization

$$\widetilde{\mathcal{L}^{(t)}} = \sum_{i=1}^{n} \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t(x_i)^2 \right] + \Omega(f_t), \quad \Omega(f) = \gamma T + \frac{1}{2}\lambda \left|\left|w\right|\right|^2$$

โดย g_i, h_i คืออนุพันธ์อันดับหนึ่งและสองของฟังก์ชันสูญเสีย (Second-order Taylor Expansion) ส่วน γ, λ ควบคุมการแตกกิ่งและขนาดน้ำหนักใบเพื่อป้องกัน Overfitting

- LightGBM พัฒนาต่อจาก GBDT โดยใช้เทคนิคหลัก 2 อย่างเพื่อเพิ่มความเร็ว:

- GOSS (Gradient-based One-Side Sampling) เก็บข้อมูลที่มี Gradient สูงไว้ทั้งหมด และสุ่มตัดข้อมูล Gradient ต่ำบางส่วน พร้อมถ่วงน้ำหนักชดเชย โดยเมื่อกำหนดสัดส่วนข้อมูล gradient สูงที่เก็บไว้ทั้งหมดเป็น a และสัดส่วนที่สุ่มจากข้อมูล gradient ต่ำเป็น b ตัวประมาณผลรวม gradient คำนวณจาก

$$\tilde{\mathrm{g}} = \sum_{\mathrm{i}\in\mathrm{A}} \mathrm{g_i} + \frac{1-\mathrm{a}}{\mathrm{b}} \sum_{\mathrm{i}\in\mathrm{B}} \mathrm{g_i}$$

โดย A คือเซตข้อมูลที่มี gradient สูง (เก็บทั้งหมด) และ B คือเซตย่อยที่สุ่มมาจากข้อมูล gradient ต่ำ ตัวคูณ (1−a)/b ทำหน้าที่ชดเชยน้ำหนักเพื่อให้ค่าคาดหวังของ g เท่ากับผลรวม gradient จริงของข้อมูลทั้งหมด

- EFB (Exclusive Feature Bundling) รวมฟีเจอร์ที่ไม่ปรากฏค่าพร้อมกันเข้าเป็นฟีเจอร์เดียวเพื่อลดมิติข้อมูล

รวมถึงใช้ Leaf-wise Tree Growth (ขยายใบที่สูญเสียมากที่สุดก่อน) และ Histogram-based Binning ทำให้เร็วกว่า GBDT ดั้งเดิมมาก แต่ต้องควบคุมความลึกของต้นไม้เพื่อไม่ให้ Overfitting

ด้วยคุณสมบัติที่แตกต่างกันของทั้งสามโมเดล ระบบจึงไม่เลือกใช้โมเดลใดโมเดลหนึ่งตายตัวแต่พัฒนาเป็นระบบจัดเส้นทางแบบมีเงื่อนไข (Dynamic Routing Layer) ที่คัดเลือกโมเดลที่เหมาะสมที่สุดโดยอัตโนมัติในแต่ละรอบเวลาพยากรณ์

4.1.2 วิศวกรรมคุณลักษณะ

ความแม่นยำของโมเดลไม่ได้ขึ้นอยู่กับอัลกอริทึมเพียงอย่างเดียว แต่ขึ้นอยู่กับคุณภาพของคุณลักษณะที่ใช้เป็นตัวแปรนำเข้าด้วย คุณลักษณะสำคัญที่ใช้ในระบบมีดังนี้

- ตัวแปรอุตุนิยมวิทยา: อุณหภูมิและความกดอากาศสัมพันธ์กับปรากฏการณ์อุณหภูมิผกผัน (Temperature Inversion) ที่กดทับมลพิษไว้ใกล้พื้นดินในฤดูหนาว ส่วนความชื้นและปริมาณฝนมีผลเชิงการชะล้าง (Scavenging Effect) ที่อาจลดหรือเร่งการสะสมของ PM2.5 ขึ้นอยู่กับสภาวะ
- Lag Features: ค่า PM2.5 ย้อนหลัง (เช่น t-1, t-24 ชั่วโมง) ใช้ดักจับพฤติกรรมความสัมพันธ์ในตัวเอง ของข้อมูล
- Rolling Window Statistics: ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานเคลื่อนที่ ช่วยลดสัญญาณรบกวนและเน้นแนวโน้มหลัก
- Date-related Features: การแยกชั่วโมง วันในสัปดาห์ วันหยุด เพื่อเป็นตัวแทน (Proxy) ของกิจกรรมมนุษย์ที่ส่งผลต่อการปล่อยมลพิษ
- Co-pollutants: NO2, SO2, O3, CO เป็นสารตั้งต้นของปฏิกิริยาเคมีแสงที่ก่อให้เกิด PM2.5 ทุติยภูมิ

4.1.3 ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: SHAP)

โมเดล Ensemble อย่าง XGBoost และ LightGBM มีลักษณะเป็น "กล่องดำ" SHAP (SHapley Additive exPlanations) ซึ่งมีรากฐานจากทฤษฎีเกมแบบร่วมมือ (Cooperative Game Theory) ช่วยกระจายอิทธิพลของแต่ละฟีเจอร์ต่อผลการทำนาย ด้วยสมการ

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!\,(|N| - |S| - 1)!}{|N|!} \big(v(S \cup \{i\}) - v(S)\big)$$

ทำให้ทราบว่าตัวแปรใด มีผลผลักดันค่า PM2.5 ขึ้นหรือลงมากน้อยเพียงใดในแต่ละช่วงเวลา

4.1.4 การสร้างภาษาธรรมชาติ (NLG)

เทคโนโลยีที่แปลงข้อมูลเชิงตัวเลข (Structured Data) ให้เป็นข้อความที่มนุษย์เข้าใจง่าย (Data-to-Text) โดยระบบจะใช้โมเดลภาษาขนาดใหญ่ (LLM) ร่วมกับ Prompt Engineering เพื่อแปลงค่าพยากรณ์และปัจจัยจาก SHAP ให้กลายเป็นคำอธิบายแนวโน้ม (Explainable Forecast) ที่ปรับโทนให้เหมาะกับแต่ละกลุ่มผู้ใช้

4.1.5 ระบบแนะนำสุขภาพตามกลุ่มผู้ใช้

ทฤษฎีเวชศาสตร์สิ่งแวดล้อมชี้ว่าความอ่อนไหวต่อ PM2.5 ไม่เท่ากันในแต่ละกลุ่มบุคคล กลุ่มเปราะบาง เช่น เด็ก ผู้สูงอายุ ผู้มีโรคทางเดินหายใจ มีความเสี่ยงสูงกว่าคนทั่วไปแม้สัมผัสมลพิษระดับเดียวกัน และอัตราการสูดดม (Inhalation Rate) จะเพิ่มขึ้นตามความหนักของกิจกรรม ระบบจึงต้องประกอบด้วย

(1) การจำแนกกลุ่มผู้ใช้ตามความเสี่ยง

(2) การคำนวณดัชนีความเสี่ยงสัมพัทธ์จากผลพยากรณ์ 24 ชั่วโมง

(3) การค้นหาช่วงเวลาที่เหมาะสม

(4) การแจ้งเตือนเชิงรุกผ่าน PWA เพื่อเปลี่ยนจากการเฝ้าระวังแบบตั้งรับสู่การป้องกันเชิงรุก

4.1.6 กลไกจัดเส้นทางโมเดลและระบบสำรองเมื่อข้อมูลขาดหาย

เนื่องจากโมเดลทั้งสามมีบทบาทต่างกัน โดย Prophet มีความทนทานต่อข้อมูลสูญหายสูงแต่ความแม่นยำต่ำกว่าในสภาวะปกติ ขณะที่ XGBoost และ LightGBM ให้ความแม่นยำสูงกว่าแต่ไวต่อข้อมูลที่ขาดหาย ระบบจึงแบ่งกลไกการเลือกโมเดล m* ในแต่ละรอบเวลาพยากรณ์ t ออกเป็น 2 ระดับตามความสมบูรณ์ของข้อมูลนำเข้า กำหนดให้ $\Delta_missing(t) \in [0, 1]$ เป็นสัดส่วนข้อมูลนำเข้าที่สูญหาย ณ เวลา t และกำหนดเกณฑ์วิกฤต $\sigma_critical$ การเลือกโมเดลเป็นไปตามเงื่อนไขแบบแบ่งส่วนดังนี้

ระดับที่ 1 — กลไกตัดวงจรภัยพิบัติข้อมูล (Data-Disruption Circuit Breaker) หาก

$\Delta_missing(t) > \sigma_critical$ ระบบจะสลับไปใช้ $m*$ = Prophet โดยอัตโนมัติ (Fail-safe Backup Mode) เพื่อใช้ความสามารถในการจัดการข้อมูลสูญหายและพฤติกรรมฤดูกาลแบบสถิติประคับประคองระบบ

ระดับที่ 2 — เลเยอร์จัดเส้นทางอัจฉริยะในสภาวะปกติ (Dynamic Routing Layer):หาก

$\Delta_missing(t) \leq \sigma_critical$ ระบบจะคัดเลือกโมเดลผ่านฟังก์ชันวัตถุประสงค์แบบพหุเกณฑ์

$$m* = argmax_\{m \in \{XGBoost, LightGBM\}\} \Phi(m)$$
$$\Phi(m) = w_1 \cdot R^2_rolling, N(m,t) - w_2 \cdot Cost(m)$$

ในกรณีที่ค่า $\Phi(m)$ ของทั้งสองโมเดลเท่ากันพอดี ระบบจะเลือก LightGBM เป็นค่าเริ่มต้น เนื่องจากมีต้นทุนการประมวลผล (Cost) ต่ำกว่าโดยเฉลี่ย เพื่อให้ฟังก์ชัน m* มีนิยามครบถ้วนในทุกกรณี

โดยที่ w_1, w_2 คือน้ำหนักถ่วงของแต่ละเกณฑ์ และ $Cost(m)$ คือทรัพยากรหรือเวลาประมวลผลของโมเดล m ส่วนค่าประสิทธิภาพ $R^2_rolling, N(m,t)$ วัดผ่านเทคนิค Sliding-Window Evaluation ซึ่งเป็นแนวทางมาตรฐานในระบบ Online Model Monitoring คำนวณจากคู่ค่าพยากรณ์และค่าจริงย้อนหลัง N ช่วงเวลาล่าสุดที่ทราบค่าจริงแล้ว ดังสมการ

$$R^2_{rolling,N}(m,t) = 1 - \frac{\sum_{\tau=t-N}^{t-1}\left(y_\tau - \widehat{y_{\tau,m}}\right)^2}{\sum_{\tau=t-N}^{t-1}(y_\tau - \overline{y_N})^2}$$

เมื่อ y_τ คือค่าจริงของ PM2.5 ที่เกิดขึ้นแล้วในชั่วโมงที่ผ่านมา และ $\hat{y}_\{\tau, m\}$ คือค่าที่โมเดล m เคยพยากรณ์ไว้ ณ เวลานั้น เนื่องจากค่าจริงของ PM2.5 ณ เวลาพยากรณ์ปัจจุบันยังไม่เกิดขึ้นการประเมินประสิทธิภาพจึงอ้างอิงจากผลการทำงานที่ผ่านมาแทนค่าแบบเรียลไทม์โดยตรง

การออกแบบสถาปัตยกรรมแบบ 2 ระดับนี้ช่วยลดค่าความหน่วงในการคำนวณ ในสภาวะปกติ เนื่องจากไม่ต้องส่งข้อมูลไป Inference บนโมเดล Prophet ในทุกรอบเวลา และการใช้ค่า $R^2_rolling, N$ ย้อนหลังยังช่วยจำกัดขอบเขตความคลาดเคลื่อนของระบบ ไม่ให้เลือกโมเดลที่เกิดการหลุดลอยของแนวโน้ม (Concept Drift) เข้ามาทำงาน

4.2 กลุ่มงานวิจัยที่เกี่ยวข้อง

การศึกษาพัฒนาการของเทคโนโลยีพยากรณ์มลพิษทางอากาศ จำเป็นต้องพิจารณาจากผลงานวิจัยเชิงวิชาการที่ได้รับการตีพิมพ์ในฐานข้อมูลระดับนานาชาติ ผู้วิจัยได้แบ่งหมวดหมู่งานวิจัยที่เกี่ยวข้องออกตามวัตถุประสงค์หลักของการประยุกต์ใช้เทคโนโลยี ดังต่อไปนี้

4.2.1 งานวิจัยด้านการเปรียบเทียบและการประยุกต์ใช้โมเดลการเรียนรู้ของเครื่อง

[1] Shen, Valagolam และ McCalla (2020) ใช้โมเดล Prophet พยากรณ์มลพิษทางอากาศหลายชนิด (PM2.5, PM10, O3, NO2, SO2, CO) ในกรุงโซล ประเทศเกาหลีใต้ โดยใช้ข้อมูลรายชั่วโมงย้อนหลัง 3 ปี ผลการทดลองพบว่า Prophet จับรูปแบบแนวโน้มและฤดูกาลได้ดีทั้งในการพยากรณ์ระยะสั้นและระยะยาว เป็นหลักฐานสนับสนุนการเลือกใช้ Prophet เป็นโมเดลพื้นฐานของระบบ

[2] Wang, Wu และ Wu (2023) พัฒนาโมเดล XGBoost เชิงพื้นที่-เวลา (Spatiotemporal) สำหรับพยากรณ์ PM2.5 ใน 16 เขตของนครเซี่ยงไฮ้ พบว่าโมเดลที่ปรับปรุงแล้วมีค่าความพอดีเพิ่มขึ้นร้อยละ 17 และค่า RMSE ลดลงร้อยละ 28 เมื่อเทียบกับโมเดลดั้งเดิม แสดงให้เห็นศักยภาพของ XGBoost ในการจับความสัมพันธ์ที่ซับซ้อนระหว่าง PM2.5 สภาพอากาศ และปัจจัยเชิงเวลา

[3] Tırınk (2025) เปรียบเทียบประสิทธิภาพของ XGBoost, LightGBM และ SVM ในการพยากรณ์ AQI ระยะยาวที่ภาคตะวันออกของตุรกี โดยใช้ข้อมูล 8 ปี (ค.ศ. 2016–2024) ผลการศึกษาพบว่า XGBoost ให้ความแม่นยำสูงสุด (R^2 = 0.999) ในขณะที่ LightGBM ตามมาด้วยความแม่นยำระดับดีเยี่ยมและประมวลผลได้เร็วกว่า งานนี้สนับสนุนการเลือก XGBoost และ LightGBM เป็นโมเดลเปรียบเทียบหลักของระบบ

4.2.2 งานวิจัยบริบทประเทศไทยและวิศวกรรมคุณลักษณะ

[4] Wongrin, Chaisee และ Suphawan (2023) เปรียบเทียบวิธีสถิติดั้งเดิมกับ Deep Learning สำหรับพยากรณ์ PM2.5 รายวันในภาคเหนือของไทย (เชียงใหม่ เชียงราย ลำปาง) เป็นวรรณกรรมพื้นฐานที่งานวิจัยไทยด้าน PM2.5 หลายฉบับอ้างอิงถึง

[5] Aman, Panyametheekul, Pawarmart, Sudhibrabha และ Manomaiphiboon (2025) พัฒนาโมเดล LightGBM สร้างข้อมูลย้อนหลัง PM2.5 ตั้งแต่ปี 1981–2022 ครอบคลุม 6 จังหวัดของไทย รวมถึงขอนแก่นโดยตรง โดยใช้ตัวแปรอุตุนิยมวิทยาและข้อมูลทัศนวิสัย พบว่า LightGBM ให้ความแม่นยำดีในทุกจังหวัด ฉบับนี้มีความสำคัญที่สุดต่อโครงงาน เพราะยืนยันความเหมาะสมของ LightGBM ในบริบทภูมิอากาศขอนแก่นโดยตรง

[6] Kawichai, Sripan, Rerkasem, Rerkasem และ Srisukkham (2025) พัฒนาโมเดลย้อนพยากรณ์ในภาคเหนือตอนบนของไทย โดยใช้ Random Forest ร่วมกับตัวแปร PM10, CO2, O3, ความกดอากาศ ปริมาณฝน ความชื้นสัมพัทธ์ อุณหภูมิ และทิศทาง/ความเร็วลม สนับสนุนแนวทาง Feature Engineering ด้านอุตุนิยมวิทยาของระบบ

4.2.3 งานวิจัยด้านการประยุกต์ใช้ Explainable AI (SHAP) เพื่ออธิบายแบบจำลองมลพิษ

[7] Yenkikar, Mishra, Bali และ Ara (2025) พัฒนากรอบพยากรณ์ AQI แบบผสม (Hybrid) ระหว่าง Random Forest กับ ARIMA โดยให้ Random Forest จับความสัมพันธ์ไม่เป็นเชิงเส้นของมลพิษ และ ARIMA แก้ไขส่วนที่เหลือ (Residual) เชิงเวลา จากนั้นใช้ SHAP วิเคราะห์อิทธิพลของตัวแปร PM2.5, NO2 และ SO2 ผลการทดลองพบว่าโมเดลผสมนี้ให้ค่า R^2 สูงถึง 0.94 งานนี้ยืนยันว่าการผนวก SHAP เข้ากับโมเดลพยากรณ์ช่วยให้ผลลัพธ์โปร่งใสและตรวจสอบได้ ซึ่งสอดคล้องโดยตรงกับแนวทาง Explainable Forecast ของระบบ

4.2.4 งานวิจัยด้านระบบแนะนำสุขภาพเชิงรุกตามกลุ่มผู้ใช้

[8] Rajesh, Ganesh Babu, Moorthy และ Easwaramoorthy (2025) พัฒนากรอบงานที่ผสาน Machine Learning (Random Forest, Gradient Boosting, XGBoost, LSTM) เข้ากับ SHAP และระบบแจ้งเตือนสุขภาพผ่านมือถือ โดยแบ่งพื้นที่ตามระดับความเสี่ยง (Health Risk Index) ที่คำนึงถึงข้อมูลประชากร เช่น สัดส่วนผู้สูงอายุและเด็ก ระบบส่งข้อความแจ้งเตือนที่ปรับตามกลุ่มเสี่ยง เช่น แนะนำให้กลุ่มเปราะบางหลีกเลี่ยงกิจกรรมกลางแจ้งเมื่อ AQI เกินระดับปลอดภัย งานนี้เป็นตัวอย่างเชิงประจักษ์ของสถาปัตยกรรม Personalized/Group-based Health Advisory ที่ระบบนี้จะพัฒนาต่อยอด

[9] D'Antoni, Smith, Auyeung และ Weinman (2017) ทบทวนวรรณกรรมอย่างเป็นระบบเกี่ยวกับปัจจัยที่ส่งผลต่อการปฏิบัติตามคำแนะนำสุขภาพที่มาพร้อมระบบเตือนคุณภาพอากาศ พบว่าอัตราการปฏิบัติตามมักต่ำกว่าที่ควร ให้ข้อมูลเชิงลึกสำหรับออกแบบข้อความแจ้งเตือนในฟีเจอร์ Proactive Alert ให้กระตุ้นพฤติกรรมได้จริง

[10] Workman, Jones, Wheeler, Campbell, Williamson, Lucani, Bowman, Cooling และ Johnston (2021) ประเมินการใช้งานแอปพลิเคชัน AirRater ในรัฐแทสเมเนีย ประเทศออสเตรเลีย ซึ่งให้ข้อมูลคุณภาพอากาศแบบเรียลไทม์ร่วมกับฟังก์ชันติดตามอาการส่วนบุคคล ผ่านการสัมภาษณ์ผู้ใช้งานจริง 42 คน พบว่าเกือบครึ่งหนึ่งของผู้ใช้เริ่มเปิดแอปเมื่อเริ่มมีอาการทางสุขภาพ และข้อมูลเฉพาะบุคคลช่วยให้ผู้ใช้ส่วนใหญ่ปรับพฤติกรรมเพื่อป้องกันสุขภาพได้จริง งานนี้เป็นหลักฐานเชิงประจักษ์ที่ยืนยันว่าคำแนะนำสุขภาพที่ปรับตามบุคคลสามารถนำไปสู่การเปลี่ยนแปลงพฤติกรรมได้จริงในทางปฏิบัติ ซึ่งสนับสนุนแนวทาง Proactive Alert ของระบบนี้

เพื่อสังเคราะห์ภาพรวมของงานวิจัยที่เกี่ยวข้องทั้งหมดให้เห็นแนวโน้มและช่องว่างอย่างเป็นระบบ ตารางต่อไปนี้นำเสนอการเปรียบเทียบงานวิจัยทั้ง 10 ฉบับข้างต้น จำแนกตามโมเดล, วิธีการ, พื้นที่ศึกษา, ผลลัพธ์หลัก, จุดเชื่อมโยงกับโครงงานนี้ และช่องว่างงานวิจัยที่พบ

ผู้แต่ง,ปี	โมเดล, วิธีการ	ข้อมูล, พื้นที่ศึกษา	ผลลัพธ์หลัก	จุดเชื่อมโยงกับโครงงาน	ช่องว่างวิจัย
Shen, Valagolam & McCalla (2020)	Prophet (additive regression)	โซล เกาหลีใต้, รายชั่วโมงย้อนหลัง 3 ปี, 6 มลพิษ	จับแนวโน้ม/ฤดูกาลได้ดีทั้งระยะสั้น-ยาว	สนับสนุนเหตุผลการเลือก Prophet เป็น fallback model	ไม่เปรียบเทียบกับ tree-based ML
Wang, Wu & Wu (2023)	XGBoost เชิงพื้นที่-เวลา	เซี่ยงไฮ้ 16 เขต	Fit เพิ่ม 17%, RMSE ลด 28%	ยืนยันศักยภาพ XGBoost จับความสัมพันธ์ซับซ้อน	เน้นความแม่นยำอย่างเดียว ไม่มีคำแนะนำสุขภาพ
Tırınk (2025)	XGBoost, LightGBM, SVM เปรียบเทียบ	ตุรกีตะวันออก 8 ปี (2016–2024)	XGBoost R^2=0.999, LightGBM รองลงมาแต่เร็วกว่า	สนับสนุนการเลือก XGBoost/LightGBM เป็นโมเดลหลัก	ไม่มี Explainability, ไม่มีบริบทเอเชียตะวันออกเฉียงใต้
Wongrin, Chaisee & Suphawan (2023)	สถิติดั้งเดิม vs Deep Learning	ภาคเหนือไทย (เชียงใหม่ เชียงราย ลำปาง)	วรรณกรรมพื้นฐานบริบทไทย	ยืนยันความเป็นไปได้ของงานวิจัย PM2.5 ในไทย	ไม่ครอบคลุมขอนแก่นและไม่มีระบบแจ้งเตือน
Aman et al. (2025)	LightGBM	6 จังหวัดไทย รวมขอนแก่น, 1981–2022	LightGBM แม่นยำดีทุกจังหวัด	ยืนยัน LightGBM เหมาะกับขอนแก่นโดยตรง	เน้นสร้างข้อมูลย้อนหลัง ไม่ใช่พยากรณ์ล่วงหน้า
Kawichai et al. (2025)	Random Forest	ภาคเหนือตอนบนไทย	สนับสนุนแนวทาง Feature Engineering ด้านอุตุนิยมวิทยา	ยืนยันชุด weather features ที่ใช้	ใช้ RF ไม่ใช่ Gradient Boosting และไม่มี Explainability
Yenkikar et al. (2025)	RF+ARIMA Hybrid + SHAP	ไม่ระบุพื้นที่ชัดเจน	R^2=0.94, SHAP ระบุ PM2.5/NO2/SO2 สำคัญสุด	ต้นแบบการผนวก SHAP เข้ากับโมเดลพยากรณ์	ไม่เชื่อมสู่คำแนะนำสุขภาพเฉพาะกลุ่ม

Rajesh et al. (2025)	RF, GB, XGBoost, LSTM + SHAP	Multi-location (real-time)	Health Risk Index ตามประชากร + แจ้งเตือนมือถือ	ต้นแบบสถาปัตยกรรม Personalized/Group-based Advisory	ไม่มีรายละเอียดการปรับ threshold ตามกิจกรรม
D'Antoni et al. (2017)	Systematic review	วรรณกรรมทบทวนพฤติกรรมผู้รับสาร	Adherence ต่อคำเตือนคุณภาพอากาศมักต่ำกว่าที่ควร	ออกแบบข้อความ Proactive Alert ให้กระตุ้นพฤติกรรมได้จริง	เป็นงานเก่า (2017), ไม่มีบริบท AI/ML
Workman et al. (2021)	AirRater app (ไม่ใช่ ML) — symptom tracking + real-time AQ/pollen	แทสเมเนีย ออสเตรเลีย, สัมภาษณ์ผู้ใช้ 42 คน	ผู้ใช้ส่วนใหญ่ปรับพฤติกรรมป้องกันสุขภาพได้จริง	หลักฐานเชิงประจักษ์ว่าคำแนะนำเฉพาะบุคคลเปลี่ยนพฤติกรรมได้จริง	ไม่ใช้ ML พยากรณ์ล่วงหน้า เป็นเพียง real-time display + self-report

ข้อสรุปจาก Synthesis Matrix: งานกลุ่ม ML+SHAP เน้นความแม่นยำและการอธิบายผล แต่ยังไม่เชื่อมกับระบบแจ้งเตือนที่พิสูจน์แล้วว่าเปลี่ยนพฤติกรรมได้จริง ส่วนงานกลุ่มพฤติกรรมและแอป ยืนยันว่าการแจ้งเตือนเฉพาะบุคคลได้ผลจริง แต่ไม่มี ML พยากรณ์ล่วงหน้าอยู่เบื้องหลัง โครงงานนี้อยู่ตรงจุดตัดที่ยังไม่มีงานใดทำ คือนำ LightGBM และ XGBoost พยากรณ์ล่วงหน้า ผนวกกับระบบแจ้งเตือนเฉพาะกลุ่ม มารวมเป็นระบบเดียว

5.วิธีการดำเนินงานวิจัย

5.1 การศึกษาค้นคว้าทฤษฎีและงานวิจัยที่เกี่ยวข้อง

คณะผู้จัดทำได้ศึกษาทฤษฎีอัลกอริทึมการเรียนรู้ของเครื่อง (Prophet, XGBoost, LightGBM) เทคนิควิศวกรรมคุณลักษณะ ทฤษฎีปัญญาประดิษฐ์ที่อธิบายได้ (SHAP) การสร้างภาษาธรรมชาติ (NLG) และทฤษฎีการประเมินความเสี่ยงเชิงกลุ่มด้านสุขภาพ ตลอดจนงานวิจัยที่เกี่ยวข้องทั้งในบริบทสากลและบริบทประเทศไทย

5.2 การศึกษาเครื่องมือที่จะใช้

5.2.1 เครื่องมือสำหรับดึงและจัดเก็บข้อมูล

- OpenAQ v3 API สำหรับข้อมูล PM2.5 ย้อนหลังจากสถานีตรวจวัดในจังหวัดขอนแก่น
- Open-Meteo Archive/Forecast API สำหรับข้อมูลสภาพอากาศ (อุณหภูมิ ความชื้น ความเร็ว ทิศทางลม ปริมาณฝน ความกดอากาศ)
- Air4Thai (กรมควบคุมมลพิษ) ใช้เป็นแหล่งข้อมูลเสริมเพื่อยืนยันความถูกต้องของค่า PM2.5

5.2.2 เครื่องมือสำหรับสร้างโมเดลการเรียนรู้ของเครื่อง

- Facebook Prophet สำหรับโมเดลพยากรณ์อนุกรมเวลาที่เน้นแนวโน้มและฤดูกาล
- XGBoost และ LightGBM สำหรับโมเดลกลุ่ม Gradient Boosting ที่ใช้คุณลักษณะเชิงตาราง
- SHAP Library สำหรับวิเคราะห์และอธิบายอิทธิพลของตัวแปรที่ส่งผลต่อค่าพยากรณ์
- Scikit-learn, Pandas, NumPy สำหรับการจัดการข้อมูลและประเมินผลโมเดล

5.2.3 เครื่องมือสำหรับสรุปผลข้อมูลด้วย AI

Large Language Model API (เช่น Gemini API หรือ OpenAI API) ใช้แปลงผลพยากรณ์และค่า SHAP ให้เป็นข้อความอธิบายภาษาไทยที่เข้าใจง่าย (Explainable Forecast)

5.2.4 เครื่องมือสำหรับการพัฒนาเว็บแอปพลิเคชัน

- ภาษาโปรแกรม: Python สำหรับระบบหลังบ้านและประมวลผลโมเดล, HTML5/CSS3/JavaScript สำหรับส่วนติดต่อผู้ใช้

- เฟรมเวิร์ก: Flask หรือ FastAPI เป็น API Gateway ฝั่งเซิร์ฟเวอร์, React หรือ Vue.js สำหรับพัฒนา Dashboard แบบ Progressive Web App (PWA)
- Web Push API สำหรับฟีเจอร์ Proactive Alert

5.2.5 ระบบจัดการฐานข้อมูล

PostgreSQL หรือ MongoDB สำหรับจัดเก็บข้อมูลคุณภาพอากาศ ข้อมูลผู้ใช้งาน และประวัติการพยากรณ์

5.3 ขั้นตอนการดำเนินงาน

5.3.1 การรวบรวมและทำความเข้าใจข้อมูล

รวบรวมข้อมูล PM2.5 ย้อนหลังจาก OpenAQ ร่วมกับข้อมูลสภาพอากาศจาก Open-Meteo เฉพาะพื้นที่จังหวัดขอนแก่น พร้อมตรวจสอบความครอบคลุมและความต่อเนื่องของข้อมูลในแต่ละสถานี

5.3.2 การเตรียมข้อมูลและวิศวกรรมคุณลักษณะ

- ทำความสะอาดข้อมูลและจัดการค่าข้อมูลสูญหายด้วยวิธี Interpolation ก่อนขั้นตอนสร้างคุณลักษณะ เพื่อป้องกันการรั่วไหลของข้อมูล (Data Leakage) และค่า NaN สะสม
- สร้าง Lag Features, Rolling Window Statistics และ Cyclical Time Encoding

5.3.3 การพัฒนาโมเดลพยากรณ์

- พัฒนาโมเดลโดยใช้อัลกอริทึม 3 รูปแบบหลัก ได้แก่ Prophet สำหรับจับแนวโน้มและฤดูกาลของ PM2.5 ในระยะกลางถึงระยะยาว, XGBoost และ LightGBM สำหรับพยากรณ์จากข้อมูลเชิงตารางโดยอาศัย Lag Features และตัวแปรสภาพอากาศ
- ปรับจูนพารามิเตอร์ (Hyperparameter Tuning) ของแต่ละโมเดลเพื่อให้ได้ความแม่นยำสูงสุด

5.3.4 การวิเคราะห์ปัจจัยด้วย SHAP

นำโมเดลที่ผ่านการฝึกสอนมาวิเคราะห์ด้วย SHAP โดยเลือกวิเคราะห์เฉพาะช่วงเวลาพยากรณ์ตัวแทน เช่น t+1, t+12 และ t+24 แทนการวิเคราะห์ทุกช่วงเวลาพยากรณ์ เพื่อระบุว่าตัวแปรใด เช่น ความเร็วลม ความชื้น ค่า PM2.5 ย้อนหลัง มีอิทธิพลต่อผลการพยากรณ์มากที่สุด และใช้ผลลัพธ์นี้เป็นข้อมูลนำเข้าสำหรับส่วน Explainable Forecast

5.3.5 การเปรียบเทียบและประเมินประสิทธิภาพโมเดล

- ทดสอบประสิทธิภาพของแต่ละโมเดลด้วยตัวชี้วัดมาตรฐาน ได้แก่ MAE, RMSE และ R^2
- คัดเลือกโมเดลที่ให้ค่าความคลาดเคลื่อนต่ำที่สุดสำหรับแต่ละช่วงเวลาพยากรณ์ (24 ชั่วโมง) เพื่อนำไปใช้งานจริงในระบบ
- พัฒนาระบบจัดเส้นทางโมเดลแบบมีเงื่อนไข (Dynamic Routing Engine) ตามฟังก์ชันการตัดสินใจในหัวข้อ 4.1.6 โดยคำนวณสัดส่วนข้อมูลสูญหายและค่า R^2 แบบย้อนหลัง (Rolling Window) ของ XGBoost และ LightGBM ในทุกรอบการพยากรณ์ เพื่อคัดเลือกโมเดลที่เหมาะสมที่สุดโดยอัตโนมัติ โดยฝังลอจิกดังกล่าวไว้เป็นเลเยอร์หนึ่งใน API Gateway

5.3.6 การพัฒนาระบบประเมินความเสี่ยงและคำแนะนำตามกลุ่มผู้ใช้

- พัฒนาระบบให้คะแนนความเสี่ยงเฉพาะบุคคล (Personalized Risk Score) โดยผสานผลพยากรณ์เข้ากับ 2 ปัจจัย ได้แก่ กลุ่มความเสี่ยงของผู้ใช้ (ทั่วไป/เด็ก-ผู้สูงอายุ/มีโรคประจำตัว) และความหนักของกิจกรรมกลางแจ้งที่ต้องการทำ เพื่อคำนวณเป็น คะแนนความเสี่ยงเดียวที่สะท้อนสถานการณ์จริงของผู้ใช้แต่ละคน
- พัฒนา Best Time Window Finder เพื่อค้นหาช่วงเวลาที่มีค่าฝุ่นต่ำที่สุดในรอบ 24 ชั่วโมงข้างหน้า

5.3.7 การพัฒนาส่วนอธิบายผลด้วยภาษาธรรมชาติ (NLG)

ออกแบบ Prompt Engineering เพื่อส่งค่าพยากรณ์และผลวิเคราะห์จาก SHAP ไปยัง LLM API แล้วแปลงเป็นข้อความอธิบายแนวโน้มภาษาไทยที่เข้าใจง่าย

5.3.8 การพัฒนาระบบแจ้งเตือนเชิงรุก (Proactive Alert)

เชื่อมต่อผลการประเมินความเสี่ยงเข้ากับ Web Push API เพื่อส่งการแจ้งเตือนล่วงหน้าไปยังผู้ใช้งานก่อนคุณภาพอากาศจะเปลี่ยนแปลงในทางที่แย่ลง โดยไม่ต้องรอให้ผู้ใช้เปิดแอปเอง

5.3.9 การพัฒนาเว็บแอปพลิเคชันและ Dashboard

พัฒนาระบบในรูปแบบ Progressive Web App (PWA) ที่แสดงค่า PM2.5 ปัจจุบัน แนวโน้มพยากรณ์ คำแนะนำเฉพาะกลุ่ม และข้อความอธิบายจาก NLG โดยรองรับการติดตั้งบนหน้าจอหลักของมือถือ

5.3.10 การทดสอบและปรับปรุงระบบ

- ทดสอบความถูกต้องของการแจ้งเตือนเทียบกับเกณฑ์ความเสี่ยงที่กำหนดไว้ในแต่ละกลุ่มผู้ใช้ โดยจำลองสถานการณ์ค่า PM2.5 ในระดับต่างๆ (ปกติ ปานกลาง สูง) และตรวจสอบว่าระบบส่งการแจ้งเตือนถูกต้องตามเกณฑ์ของแต่ละกลุ่ม เช่น กลุ่มเสี่ยงสูงต้องได้รับการแจ้งเตือนที่ระดับฝุ่นต่ำกว่ากลุ่มทั่วไปตามที่ออกแบบไว้
- ทดสอบความสอดคล้องของคำแนะนำที่ระบบให้กับสถานการณ์ค่า PM2.5 จริงในช่วงทดสอบ โดยเปรียบเทียบคำแนะนำที่ระบบสร้างขึ้น เช่น ช่วงเวลาที่เหมาะสมสำหรับกิจกรรมกลางแจ้ง กับข้อมูล PM2.5 ที่เกิดขึ้นจริงในช่วงเวลาเดียวกัน เพื่อตรวจสอบว่าคำแนะนำสมเหตุสมผลและไม่ขัดแย้งกับสถานการณ์จริง
- ทดสอบการใช้งานจริงบนอุปกรณ์ โดยติดตั้งระบบในรูปแบบ PWA บนโทรศัพท์มือถือ ตรวจสอบการแสดงผล Dashboard การทำงานของ Push Notification และความลื่นไหลในการใช้งานทั่วไป

6.ขอบเขตและข้อจำกัด

6.1 ขอบเขตการทำงานของระบบ

6.1.1 ส่วนจัดการและประมวลผลข้อมูล

- ระบบดึงข้อมูล PM2.5 และข้อมูลสภาพอากาศย้อนหลังจากแหล่งข้อมูลสาธารณะ (OpenAQ, Open-Meteo, Air4Thai) โดยอัตโนมัติ
- ระบบมีฟังก์ชันทำความสะอาดข้อมูลและจัดการค่าข้อมูลสูญหายโดยอัตโนมัติ (interpolation / forward-fill ตามช่วงเวลาที่กำหนด)
- ระบบมีการสร้างคุณลักษณะข้อมูล (Feature Engineering) เช่น ค่า PM2.5 ย้อนหลัง (lag features) ค่าสถิติเคลื่อนที่ (rolling statistics) และตัวแปรเชิงเวลา เพื่อเตรียมข้อมูลสำหรับโมเดล
- ระบบมีกลไกตรวจสอบคุณภาพของข้อมูลนำเข้าเบื้องต้น (Data Quality Check) บนข้อมูลเรียลไทม์จาก Air4Thai เช่น การตรวจจับค่าที่กระโดดผิดปกติ (spike), ค่าติดลบ, หรือค่าคงที่ต่อเนื่องผิดปกติ (sensor stuck) เพื่อลดความเสี่ยงจากข้อมูลผิดพลาดของเซนเซอร์ก่อนนำเข้าสู่กระบวนการพยากรณ์

6.1.2 ส่วนโมเดลการเรียนรู้ของเครื่อง

- ทำการฝึกสอนโมเดลเพื่อพยากรณ์ค่า PM2.5 ล่วงหน้า 24 ชั่วโมง โดยเปรียบเทียบประสิทธิภาพระหว่าง XGBoost และ LightGBM ด้วยตัวชี้วัด MAE, RMSE และ R^2
- เนื่องจากไม่สามารถคำนวณค่า R^2 ณ เวลาพยากรณ์ปัจจุบันได้ทันที (ค่าจริงของ PM2.5 ในอนาคตยังไม่เกิดขึ้น) ระบบจึงใช้ค่า Rolling R^2 ที่คำนวณจากคู่ค่าพยากรณ์และค่าจริงย้อนหลัง N ชั่วโมงที่ผ่านมา โดยอัปเดตทุกครั้งที่มีข้อมูลจริงใหม่จาก Air4Thai
- ระบบใช้ค่า Rolling R^2 ล่าสุดเป็นเกณฑ์คัดเลือกโมเดลที่เหมาะสมที่สุดระหว่าง XGBoost และ LightGBM สำหรับรอบการพยากรณ์ถัดไป ตามฟังก์ชันการตัดสินใจของระบบจัดเส้นทางโมเดลแบบมีเงื่อนไข (Dynamic Routing Layer) ที่ระบุไว้ในหัวข้อ 4.1.6
- กำหนดให้ Prophet เป็นเส้นทางทางเลือกของระบบจัดเส้นทางโมเดล ซึ่งจะถูกเลือกโดยอัตโนมัติเฉพาะเมื่อสัดส่วนข้อมูลนำเข้าที่ขาดหาย (เช่น ค่า lag หรือ rolling features) เกินเกณฑ์ที่กำหนดไว้เท่านั้น เนื่องจาก Prophet ไม่พึ่งพาคุณลักษณะย้อนหลังเหล่านี้จึงมีความทนทานต่อข้อมูลสูญหายมากกว่า
- สามารถพยากรณ์แนวโน้มค่า PM2.5 ล่วงหน้าตามช่วงเวลาที่กำหนดได้อย่างต่อเนื่อง

6.1.3 ส่วนแสดงผลและสรุปข้อมูล

แสดงผลในรูปแบบ Web Dashboard / Progressive Web App (PWA) ที่ใช้งานง่าย ติดตั้งบนหน้าจอหลักของโทรศัพท์มือถือได้แสดงกราฟเปรียบเทียบค่า PM2.5 ที่เกิดขึ้นจริงในอดีตกับค่าที่พยากรณ์ได้ พร้อมแนวโน้มในอนาคตสรุปข้อมูลออกมาเป็นข้อความอธิบายแนวโน้มด้วยภาษาธรรมชาติ (Explainable Forecast)

6.1.4 ส่วนสนับสนุนการตัดสินใจ

- ประเมินคะแนนความเสี่ยงเฉพาะบุคคล (Personalized Risk Score) โดยผสานกลุ่ม ความเสี่ยงของผู้ใช้งาน (Group-based) เข้ากับความหนักของกิจกรรมกลางแจ้ง (Activity-aware) เป็นคะแนนความเสี่ยงเดียว
- ค้นหาช่วงเวลาที่มีค่าฝุ่นต่ำที่สุดในแต่ละวันโดยอัตโนมัติ (Best Time Window Finder)
- แจ้งเตือนล่วงหน้าเชิงรุก (Proactive Alert) ผ่าน Web Push API เมื่อผลการพยากรณ์แสดงแนวโน้มว่าคุณภาพอากาศจะเปลี่ยนแปลงในทางที่แย่ลง
- ก่อนส่งข้อความคำแนะนำผ่าน Push Notification ระบบมีการตรวจสอบความสอดคล้องเบื้องต้นโดยเปรียบเทียบระดับคำแนะนำที่ได้จากกระบวนการ NLG กับเกณฑ์มาตรฐานดัชนีคุณภาพอากาศ หากพบความไม่สอดคล้องกัน ระบบจะใช้ข้อความสำเร็จรูป (Template-based Message) แทนเพื่อความปลอดภัยของผู้ใช้งาน

6.2 สิ่งที่อยู่นอกขอบเขตของโครงงาน

- ไม่สร้างอุปกรณ์วัดฝุ่นเอง
- ไม่วิเคราะห์หรือวินิจฉัยโรคของผู้ใช้งาน
- ไม่ควบคุมอุปกรณ์ภายนอก
- ไม่พัฒนาเป็น Native Application (iOS/Android) ที่ต้องติดตั้งผ่าน App Store หรือ Play Store
- ระบบพยากรณ์ครอบคลุมเฉพาะพื้นที่จังหวัดขอนแก่น โดยใช้ข้อมูลจากสถานีตรวจวัดที่มีข้อมูลใช้งานได้จริงในปัจจุบัน

6.3 แนวทางการขยายผลในอนาคต

เนื่องจากข้อจำกัดด้านระยะเวลาของการดำเนินงาน แนวคิดต่อไปนี้จะถูกบันทึกไว้เป็นแนวทางการพัฒนาต่อยอดในอนาคต

- การบันทึกหลักฐานธรรมาภิบาลข้อมูลแบบเข้ารหัสที่แก้ไขไม่ได้ (Immutable Audit Ledger) ด้วยเทคนิค Cryptographic Hashing (SHA-256) สำหรับทุกทรานแซกชันการพยากรณ์และคำแนะนำ
- การปรับระดับความเสี่ยงเฉพาะบุคคลแบบต่อเนื่อง (Continuous Personalization) โดยพิจารณาระยะเวลาการสัมผัสอากาศภายนอกสะสมและอัตราการสูดดม แทนการแบ่งกลุ่มผู้ใช้แบบคงที่
- การตรวจสอบความปลอดภัยของคำแนะนำสุขภาพด้วยระบบ Generator-Critic Loop โดยใช้แบบจำลองภาษาขนาดใหญ่ตัวที่สองทำหน้าที่ตรวจสอบความถูกต้องของข้อความก่อนเผยแพร่ (แทนที่การตรวจสอบแบบ Rule-based Threshold ที่ใช้ในระยะแรก)
- การตรวจสอบความสอดคล้องของข้อมูลระหว่างสถานีตรวจวัดหลายจุด (Sensor Tension Check) เพื่อเพิ่มความน่าเชื่อถือของข้อมูลที่แสดงผลแบบเรียลไทม์บน Dashboard

7.สถานที่ทำวิจัย

สาขาวิชาวิทยาการคอมพิวเตอร์วิทยาลัยการคอมพิวเตอร์ มหาวิทยาลัยขอนแก่น

8.ประโยชน์ที่คาดว่าจะได้รับ

1. ผู้ใช้งานสามารถทราบแนวโน้มค่า PM2.5 ล่วงหน้า และวางแผนกิจกรรมกลางแจ้งได้อย่างเหมาะสม แทนที่จะทราบเพียงค่าปัจจุบัน

2. กลุ่มเสี่ยง เช่น เด็ก ผู้สูงอายุ ผู้มีโรคประจำตัวทางระบบหายใจ ได้รับคำแนะนำที่ปรับตามระดับความเสี่ยงของตนเอง ช่วยลดโอกาสเกิดภาวะแทรกซ้อนจากการสัมผัสมลพิษ

3. ผู้ใช้งานได้รับการแจ้งเตือนล่วงหน้าก่อนสถานการณ์คุณภาพอากาศจะแย่ลง โดยไม่ต้องเปิดแอปพลิเคชันตรวจสอบด้วยตนเองตลอดเวลา

4. ผู้ใช้งานที่ต้องการทำกิจกรรมกลางแจ้ง เช่น วิ่งหรือปั่นจักรยาน สามารถทราบช่วงเวลาที่มีค่าฝุ่นต่ำที่สุดในแต่ละวันได้โดยอัตโนมัติ โดยไม่ต้องวิเคราะห์กราฟหรือข้อมูลด้วยตนเอง

9.ระยะเวลาการดำเนินงาน

การดำเนินงาน	ปี/เดือน								
	ปี 2569						ปี 2570		
	ก.ค.	ส.ค.	ก.ย.	ต.ค.	พ.ย.	ธ.ค.	ม.ค.	ก.พ.	มี.ค.
ศึกษาค้นคว้าทฤษฎีและงานวิจัยที่เกี่ยวข้อง									
รวบรวมและทำความเข้าใจข้อมูล									
เตรียมข้อมูลและวิศวกรรมคุณลักษณะ									
พัฒนาโมเดลพยากรณ์									
เปรียบเทียบประสิทธิภาพโมเดล									
พัฒนาระบบประเมินความเสี่ยงและคำแนะนำตามกลุ่มผู้ใช้									
พัฒนาระบบแจ้งเตือนและอธิบายผล									
ออกแบบเว็บแอปพลิเคชัน									
พัฒนาเว็บแอปพลิเคชัน									
ทดสอบและปรับปรุงระบบ									
นำเสนอ									

10.งบประมาณ

หมวดวัสดุอุปกรณ์

- ค่าวัสดุสำนักงาน (กระดาษ ปากกา ฯลฯ) ประมาณ 200 – 300 บาท
- ค่าวัสดุคอมพิวเตอร์ (อุปกรณ์เสริมสำหรับพัฒนาระบบ) ประมาณ 2,000 – 4,000 บาท

หมวดค่าใช้สอย

- ค่าถ่ายเอกสาร ประมาณ 300 – 400 บาท
- ค่าจัดรูปเล่ม/เข้าเล่ม (1–2 เล่ม) ประมาณ 300 – 500 บาท

หมวดค่าใช้จ่ายด้านระบบและการ Deploy

- ค่าเช่า Cloud Server (VPS) สำหรับรันเว็บแอปพลิเคชันและฐานข้อมูล ประมาณ 300 – 500 บาท/เดือน
- ค่าจดโดเมนเนม ประมาณ 50 – 60 บาท/เดือน
- ค่าบริการ AI API Credits ประมาณ 2,000 บาท
- ค่าบริการ Database Cloud ประมาณ 500 บาท

11.เอกสารอ้างอิง

1. Shen, J., Valagolam, D., & McCalla, S. (2020). Prophet forecasting model: a machine learning approach to predict the concentration of air pollutants (PM2.5, PM10, O3, NO2, SO2, CO) in Seoul, South Korea. PeerJ, 8, e9961. https://doi.org/10.7717/peerj.9961

2. Wang, Z., Wu, X., & Wu, Y. (2023). A spatiotemporal XGBoost model for PM2.5 concentration prediction and its application in Shanghai. Heliyon, 9(12), e22569. https://doi.org/10.1016/j.heliyon.2023.e22569

3. Tırınk, S. (2025). Machine learning-based forecasting of air quality index under long-term environmental patterns: A comparative approach with XGBoost, LightGBM, and SVM. PLOS ONE, 20(10), e0334252. https://doi.org/10.1371/journal.pone.0334252

4. Wongrin, W., Chaisee, K., & Suphawan, K. (2023). Comparison of statistical and deep learning methods for forecasting PM2.5 concentration in northern Thailand. Polish Journal of Environmental Studies, 32(3), 1419–1431. https://doi.org/10.15244/pjoes/157072

5. Aman, N., Panyametheekul, S., Pawarmart, I., Sudhibrabha, S., & Manomaiphiboon, K. (2025). A visibility-based historical PM2.5 estimation for four decades (1981–2022) using machine learning in Thailand: Trends, meteorological normalization, and influencing factors using SHAP analysis. Aerosol and Air Quality Research, 25(1), 4. https://doi.org/10.1007/s44408-025-00007-z

6. Kawichai, S., Sripan, P., Rerkasem, A., Rerkasem, K., & Srisukkham, W. (2025). Long-term retrospective predicted concentration of PM2.5 in upper northern Thailand using machine learning models. Toxics, 13(3), 170. https://doi.org/10.3390/toxics13030170

7. Yenkikar, A., Mishra, V. P., Bali, M., & Ara, T. (2025). Explainable forecasting of air quality index using a hybrid random forest and ARIMA model. MethodsX, 15, 103517. https://doi.org/10.1016/j.mex.2025.103517

8. Rajesh, M., Ganesh Babu, R., Moorthy, U., & Easwaramoorthy, S. V. (2025). Machine learning-driven framework for realtime air quality assessment and predictive environmental health risk mapping. Scientific Reports, 15, 28801. https://doi.org/10.1038/s41598-025-14214-6

9. D'Antoni, D., Smith, L., Auyeung, V., & Weinman, J. (2017). Psychosocial and demographic predictors of adherence and non-adherence to health advice accompanying air quality warning systems: a systematic review. Environmental Health, 16, 100. https://doi.org/10.1186/s12940-017-0307-4

10. Workman, A., Jones, P. J., Wheeler, A. J., Campbell, S. L., Williamson, G. J., Lucani, C., Bowman, D. M. J. S., Cooling, N., & Johnston, F. H. (2021). Environmental hazards and behavior change: User perspectives on the usability and effectiveness of the AirRater smartphone app. International Journal of Environmental Research and Public Health, 18(7), 3591. https://doi.org/10.3390/ijerph18073591

ภาคผนวก ก: การตรวจสอบความถูกต้องของสมการด้วย Lean 4 Proof Sketches

เนื่องจากสูตรในหัวข้อ 4.1 มีความเสี่ยงต่อข้อผิดพลาด ภาคผนวกนี้จึงตรวจสอบความถูกต้องของสูตรแต่ละตัวในเชิง type correctness, well-definedness, และ mathematical consistency ก่อนนำไปใช้งานจริง โดยแสดงเป็นข้อความพิสูจน์อย่างไม่เป็นทางการ ประกอบด้วย pseudo-Lean 4 signature เพื่อระบุ type และ lemma ที่ควรตรวจสอบ ไม่ใช่ Lean code ที่ compile ได้จริง

ก.1 Prophet Additive Model

สูตรตั้งต้น $y(t) = g(t) + s(t) + h(t) + \varepsilon_t$

การตรวจสอบ: เป็นการแยกส่วนบวก (additive decomposition) โดยแต่ละพจน์เป็นฟังก์ชัน $\mathbb{R} \longrightarrow \mathbb{R}$ จึงรวมกันได้ถูกต้องตามมิติ (type-correct) g(t) เป็นแนวโน้มแบบ piecewise-linear หรือ logistic, s(t) ประมาณด้วยอนุกรมฟูเรียร์ $s(t) = \Sigma_{\mathrm{n=1}}{}^{\mathrm{N}} (a_{\mathrm{n}} cos(2\pi nt/P) + b_{\mathrm{n}} sin(2\pi nt/P))$ ซึ่งมีคาบ P แน่นอนและมีขอบเขต (bounded) เมื่อสัมประสิทธิ์ $a_{\mathrm{n}}, b_{\mathrm{n}}$ มีขอบเขต $h(t)$ เป็นผลรวมเชิงเส้นของ indicator function สำหรับวันหยุด $\varepsilon_t \sim N(0, \sigma^2)$ เป็น white noise อิสระ

```
-- pseudo-Lean 4 sketch (ไม่ได้ compile จริง)
def trend (t : ℝ) : ℝ := ...        -- piecewise linear / logistic

def seasonality (t : ℝ) (P : ℝ) (a b : Fin N → ℝ) : ℝ :=
  ∑ n, (a n * Real.cos (2 * Real.pi * n * t / P)
      + b n * Real.sin (2 * Real.pi * n * t / P))

def holiday (t : ℝ) : ℝ := ...

theorem seasonality_bounded (a b : Fin N → ℝ) (P : ℝ) (hP : P > 0) :
    ∃ M, ∀ t, |seasonality t P a b| ≤ M := by
  sorry
  -- ตามมาจาก |cos|,|sin| ≤ 1 และผลรวมจำกัด N พจน์

theorem prophet_well_typed (g s h : ℝ → ℝ) (t : ℝ) :
    ∃ y : ℝ, y = g t + s t + h t := ⟨_, rfl⟩
  -- trivial, ยืนยันมิติถูกต้อง λ > 0) (T : ℕ) :
    ConvexOn ℝ Set.univ (regTerm γ λ T) := by
  sorry
  -- Hessian = λ·I ≥ 0 เมื่อ λ > 0
```

โค้ด ก.1: pseudo-Lean 4 sketch สำหรับ Prophet

ข้อสังเกต สูตรถูกต้องตามทฤษฎีต้นฉบับของ Prophet (Taylor & Letham, 2018) ไม่พบข้อผิดพลาด ค่า N (จำนวนพจน์ฟูเรียร์) และ P (คาบ เช่น 24 ชม./365 วัน) ที่ใช้จริงในการทดลองจะระบุในขั้นตอนพัฒนาโมเดล (หัวข้อ 5.3.3)

ก.2 XGBoost Regularized Objective

การตรวจสอบ: สูตรนี้มาจาก Taylor expansion อันดับ 2 ของ loss function $l(y_i, \hat{y}^{(t-1)} + f_t(x_i))$ รอบจุด $\hat{y}^{(t-1)}$ โดย $g_i = \partial l / \partial \hat{y}^{(t-1)}$ (อนุพันธ์อันดับ 1) และ $h_i = \partial^2 l / \partial \hat{y}^{(t-1)2}$ (อนุพันธ์อันดับ 2) โดยสมมติว่า l เป็น C^2 และ f_t มีขนาดเล็กพอให้ตัด remainder ของ Taylor series ได้ ส่วน $\Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2$ เป็นฟังก์ชัน convex ใน w เมื่อ $\lambda > 0$ (Hessian ของ Ω เป็น positive definite) ซึ่งจำเป็นต่อการมี closed-form solution ของ $w*$ ในแต่ละใบ

```
-- pseudo-Lean 4 sketch
def taylorObjective (l : ℝ → ℝ → ℝ) (y_pred_prev : ℝ) (f_t : ℝ) (g h : ℝ) : ℝ :=
  g * f_t + (1/2) * h * f_t^2

theorem taylor_second_order_approx (l : ℝ → ℝ → ℝ) (y ŷ f_t : ℝ)
    (hl : ContDiff ℝ 2 (l y)) :
    ∃ R, l y (ŷ + f_t) = l y ŷ + (deriv (l y) ŷ) * f_t
         + (1/2) * (deriv (deriv (l y)) ŷ) * f_t^2 + R
       ∧ (R = O(f_t^3)) := by
  sorry
  -- Taylor's theorem, remainder term

def regTerm (γ λ : ℝ) (T : ℕ) (w : Fin T → ℝ) : ℝ :=
  γ * T + (1/2) * λ * (∑ j, (w j)^2)

theorem regTerm_convex (γ λ : ℝ) (hλ : λ > 0) (T : ℕ) :
    ConvexOn ℝ Set.univ (regTerm γ λ T) := by
  sorry
  -- Hessian = λ·I ≥ 0 เมื่อ λ > 0
```

โค้ด ก.2: pseudo-Lean 4 sketch สำหรับ XGBoost Regularized Objective

ข้อสังเกต: สูตรถูกต้องและตรงกับ paper ต้นฉบับ (Chen & Guestrin, 2016) เงื่อนไข $\lambda > 0$ เป็นข้อกำหนดจำเป็นสำหรับ convexity ของ regularization term ในการทดลองจริงจึงต้องกำหนด $\lambda > 0$ เสมอเพื่อความเสถียรของ closed-form solution เมื่อบางใบมีข้อมูลน้อย

ก.3 LightGBM: GOSS และ EFB

สูตรตั้งต้น: $\tilde{g} = \Sigma_{i} \in A\ g_{i} + (1-a)/b \cdot \Sigma_{i} \in B\ g_{i}$

การตรวจสอบ: ประเด็นสำคัญของ GOSS คือตัวคูณ (1−a)/b ต้องทำให้ค่าประมาณเท่ากับผลรวม gradient จริงของประชากรทั้งหมด ไม่ใช่แค่การถ่วงน้ำหนักลอยๆ proof goal ด้านล่างระบุความเท่ากันนี้อย่างชัดเจนโดยมีสมมติฐาน h_sample_expectation แทนความสัมพันธ์ระหว่างผลรวมของกลุ่มตัวอย่างกับกลุ่มประชากร ส่วน EFB ต้องพิสูจน์ว่าเมื่อไม่มี conflict ระหว่างฟีเจอร์ในมัดเดียวกัน จะมีฟีเจอร์ที่ active อยู่เพียงตัวเดียวในแต่ละตำแหน่งข้อมูล ทำให้ reconstruct ค่าเดิมกลับมาได้แบบไม่สูญเสียข้อมูล



```
-- pseudo-Lean 4 sketch (ปรับปรุงใหม่)
def gossEstimate (topGrad restSample : Finset N) (grad : N → ℝ) (a b : ℝ) : ℝ :=
  (∑ i in topGrad, grad i) + ((1 - a) / b) * (∑ i in restSample, grad i)

theorem goss_unbiased (grad : N → ℝ) (topGrad restPopulation restSample : Finset N)
    (a b : ℝ) (hab : 0 < b)
    (h_sample_expectation :
      ∑ i in restSample, grad i = b * ∑ i in restPopulation, grad i) :
    gossEstimate topGrad restSample grad a b =
    (∑ i in topGrad, grad i) + (1 - a) * (∑ i in restPopulation, grad i) := by
  sorry
  -- แทนค่า h_sample_expectation แล้วยกเลิก b ได้เพราะ b > 0

def bundleReconstructible (features : List (N → ℝ)) (conflictRate : ℝ) : Prop :=
  conflictRate = 0 → ∀ i, ∃! f ∈ features, f i ≠ 0

theorem efb_lossless_when_disjoint (features : List (N → ℝ)) (i : N)
    (h_no_conflict : bundleReconstructible features 0) :
    ∃ f_active ∈ features, f_active i ≠ 0 ∧
      ∀ f_other ∈ features, f_other ≠ f_active → f_other i = 0 := by
  sorry
  -- unpacked จาก ∃! ในนิยาม bundleReconstructible
```

โค้ด ก.3: pseudo-Lean 4 sketch สำหรับ LightGBM: GOSS และ EFB

ข้อสังเกต: การตรวจสอบพบว่าคำบรรยายเชิงข้อความเพียงอย่างเดียวไม่เพียงพอต่อการยืนยันว่าตัวประมาณเป็น unbiased estimator จึงเพิ่มสมการตัวคูณ (1−a)/b กำกับไว้ในหัวข้อ 4.1.1 เพื่อความชัดเจนทางคณิตศาสตร์ สอดคล้องกับนิยามต้นฉบับของ LightGBM นอกจากนี้ theorem ทั้งสองตัวในภาคผนวกนี้ได้ปรับจาก goal แบบ True เป็น proof goal ที่ระบุความสัมพันธ์เชิงพีชคณิตของ GOSS และเงื่อนไขการ reconstruct ของ EFB อย่างชัดเจน เพื่อให้ sketch มีเนื้อหาทางคณิตศาสตร์ที่ตรวจสอบได้จริง

ก.4 SHAP

สูตรตั้งต้น: $\varphi_i(v) = \Sigma_{S \subseteq N \setminus \{i\}} [|S|!\,(|N| - |S| - 1)!/|N|!]\,(v(S \cup \{i\}) - v(S))$

การตรวจสอบ: เป็นสูตร Shapley value มาตรฐานจากทฤษฎีเกม (Shapley, 1953) คุณสมบัติสำคัญที่ต้องตรวจสอบ คือ $Efficiency\ Axiom: \Sigma_i\, \varphi_i(v) = v(N) - v(\emptyset)$ ซึ่งพิสูจน์ได้จาก combinatorial identity — ผลรวมน้ำหนักของทุก permutation ที่เป็นไปได้ของ N ต้องเท่ากับ 1 พอดี

```
-- pseudo-Lean 4 sketch
noncomputable def shapley (N : Finset N) (v : Finset N → ℝ) (i : N) : ℝ :=
  ∑ S in N.erase i |>.powerset,
    (S.card.factorial * (N.card - S.card - 1).factorial : ℝ) / N.card.factorial
    * (v (insert i S) - v S)

theorem shapley_efficiency (N : Finset N) (v : Finset N → ℝ) :
    ∑ i in N, shapley N v i = v N - v ∅ := by
  sorry
  -- combinatorial identity: ผลรวมน้ำหนักตาม permutation ทั้งหมด = 1

theorem shapley_weight_sums_to_one (N : Finset N) (i : N) (hi : i ∈ N) :
    ∑ S in N.erase i |>.powerset,
      (S.card.factorial * (N.card - S.card - 1).factorial : ℝ)
      / N.card.factorial = 1 := by
  sorry
  -- lemma ย่อยที่ efficiency axiom อาศัย
```

โค้ด ก.4: pseudo-Lean 4 sketch สำหรับ SHAP

ข้อสังเกต: สูตรถูกต้องตรงตามนิยามดั้งเดิม ไม่พบข้อผิดพลาด เป็นสูตรเดียวใน 6 ตัวที่มี combinatorial identity ชัดเจนพอจะ verify ได้เข้มงวดที่สุดถ้าต้องการ formalize ด้วย Lean 4 จริง

ก.5 Rolling R² (Sliding-Window Evaluation)

สูตรตั้งต้น: $R^2_{rolling,N}(m,t) = 1 - \frac{\sum_{\tau=t-N}^{t-1}(y_\tau - \widehat{y_{\tau,m}})^2}{\sum_{\tau=t-N}^{t-1}(y_\tau - \overline{y_N})^2}$

การตรวจสอบ: เป็นสูตร R^2 มาตรฐาน แต่คำนวณบนหน้าต่างเลื่อน (rolling window) ขนาด N แทนที่จะเป็นทั้ง dataset ต้องตรวจสอบ well-definedness: ตัวหาร ต้องไม่เป็นศูนย์ ซึ่งจะเป็นศูนย์ก็ต่อเมื่อ y_τ ทุกค่าในหน้าต่างเท่ากันหมด นอกจากนี้ต่างจาก R^2 แบบมาตรฐาน rolling R^2 ไม่มีขอบเขตล่างที่ 0 — proof goal ด้านล่างระบุทั้งสองคุณสมบัตินี้อย่างชัดเจนแทนที่จะใช้ goal แบบ True

```
-- pseudo-Lean 4 sketch
def ybar (N t : ℕ) (y : ℕ → ℝ) : ℝ :=
  (∑ τ in Finset.Ico (t - N) t, y τ) / N

def ssTot (N t : ℕ) (y : ℕ → ℝ) : ℝ :=
  ∑ τ in Finset.Ico (t - N) t, (y τ - ybar N t y) ^ 2

def rollingR2 (N t : ℕ) (y yhat : ℕ → ℝ) : ℝ :=
  1 - (∑ τ in Finset.Ico (t - N) t, (y τ - yhat τ) ^ 2) / ssTot N t y

theorem rollingR2_well_defined (N t : ℕ) (y : ℕ → ℝ)
    (hvar : ∃ τ₁ τ₂, τ₁ ∈ Finset.Ico (t - N) t ∧ τ₂ ∈ Finset.Ico (t - N) t
            ∧ y τ₁ ≠ y τ₂) :
    0 < ssTot N t y := by
  sorry
  -- ผลรวมกำลังสองมีอย่างน้อยหนึ่งพจน์ไม่เป็นศูนย์ เมื่อมีค่าต่างกันในหน้าต่าง

theorem rollingR2_can_be_negative (N t : ℕ) :
    ∃ y yhat : ℕ → ℝ, rollingR2 N t y yhat < 0 := by
  sorry
  -- ตัวอย่างที่ ssRes > ssTot ทำให้ R² ติดลบได้ไม่จำกัด
```

โค้ด ก.5: pseudo-Lean 4 sketch สำหรับ Rolling R² (Sliding-Window Evaluation)

ข้อสังเกต: ต่างจาก R² แบบมาตรฐานที่มักอยู่ในช่วง [0,1] ในทางปฏิบัติ rolling R² ไม่มีขอบเขตล่าง สามารถติดลบได้มาก หากโมเดลพยากรณ์แย่กว่าค่าเฉลี่ยของหน้าต่างนั้นๆ ในช่วงที่ PM2.5 ผันผวนสูง (เช่น ช่วงเปลี่ยนฤดู) ค่านี้อาจติดลบบ่อยครั้ง — ระบุพฤติกรรมนี้ไว้ล่วงหน้าเพื่อไม่ให้เข้าใจผิดว่าเป็นบั๊กระหว่างทดสอบระบบจริง

ก.6 Model Routing Function $\Phi(m)$

สูตรตั้งต้น: $m* = argmax_{m \in XGBoost, LightGBM} \Phi(m)$,

$$\Phi(m) = w_1 \cdot R^2_rolling, N(m,t) - w_2 \cdot Cost(m)$$

(ภายใต้เงื่อนไขแบ่งส่วนกับ Prophet fallback เมื่อ $\Delta_missing(t) > \sigma_critical$)

การตรวจสอบ: ฟังก์ชัน piecewise ทั้งระบบ (Circuit Breaker ระดับ 1 + Routing Layer ระดับ 2) ต้องเป็น total function คือครอบคลุมทุกค่าที่เป็นไปได้ของ $\Delta_missing(t) \in [0,1]$ โดยไม่มีช่องว่างหรือทับซ้อนกัน จากเงื่อนไข $\Delta_missing(t) > \sigma_critical$ ใช้ Prophet และ $\Delta_missing(t) \leq \sigma_critical$ ใช้ argmax $\Phi(m)$ ครอบคลุมครบทุกค่าด้วยหลัก trichotomy ของจำนวนจริง ส่วน argmax บนเซตจำกัด {XGBoost, LightGBM} รับประกันว่ามีคำตอบเสมอ และมี tie-breaking rule กำกับไว้แล้ว (เลือก LightGBM เมื่อ Φ เท่ากัน ตามที่ระบุในหัวข้อ 4.1.6) ทำให้ฟังก์ชัน $m*$ มีนิยามครบถ้วนในทุกกรณี

```
-- pseudo-Lean 4 sketch
def circuitBreaker (deltaMissing sigmaCritical : ℝ) (t : ℕ)
    (phiXGB phiLGBM : ℝ) : String :=
  if deltaMissing > sigmaCritical then "Prophet"
  else if phiXGB ≥ phiLGBM then "XGBoost"
  else "LightGBM"
  -- tie-break: default ไป LightGBM เมื่อ Φ เท่ากัน (ตามหัวข้อ 4.1.6)

theorem circuitBreaker_total (deltaMissing sigmaCritical : ℝ) (t : ℕ)
    (phiXGB phiLGBM : ℝ) :
    ∃ result, circuitBreaker deltaMissing sigmaCritical t phiXGB phiLGBM = result :=
  ⟨_, rfl⟩
  -- total function เพราะ if-then-else ครอบคลุมทุกกรณี

theorem circuitBreaker_no_gap_no_overlap (deltaMissing sigmaCritical : ℝ) :
    (deltaMissing > sigmaCritical) ∨ (deltaMissing ≤ sigmaCritical) :=
  le_or_lt sigmaCritical deltaMissing
  -- trichotomy ของจำนวนจริง รับประกันครบทุกกรณี
```

โค้ด ก.6: pseudo-Lean 4 sketch สำหรับ Model Routing Function $\Phi(m)$

ข้อสังเกต: นิยาม $m* = \ argmax\ \Phi(m)$ เดิมไม่ครอบคลุมกรณี

$\Phi(XGBoost) \ = \ \Phi(LightGBM)$ พอดี จึงเพิ่ม tie-breaking rule ในหัวข้อ 4.1.6 ทำให้ฟังก์ชันการเลือกโมเดลทั้งระบบเป็น total function ที่มีนิยามครบถ้วน

ลงชื่อผู้ทำโครงงาน .....

.....

(นาย/นางสาว .....)

(นาย/นางสาว .....)

วันที่ .....

การตรวจสอบจากอาจารย์ที่ปรึกษาโครงงาน

.....

.....

.....

(ลงชื่อ) .....

(.....)

วันที่...../...../.....